INFORME DE ANÁLISIS

Tópicos en reseñas de IMDb en español

Modelado exploratorio con BERTopic · 30 de octubre de 2026

Resumen

Se analizaron 4,830 reseñas de una muestra reproducible de 5,000 textos únicos de la columna review_es. La configuración general produjo 10 tópicos; HDBSCAN marcó inicialmente 60.43% como outliers. Tras la reasignación por similitud quedó 0.29% sin asignar. Los temas encontrados son exploratorios: hay grupos reconocibles, pero también solapamiento y tópicos amplios.

Alcance

Reporte basado en los archivos y resultados disponibles; la interpretación de cada tópico se considera tentativa y debe leerse junto con sus ejemplos.

Corpus: IMDB Dataset SPANISH.csv
Variable analizada: review_es
Código: [agregar enlace al repositorio]

1. Corpus y segmentación

Descripción del corpus local y del subconjunto utilizado para modelar.

Descripción del corpus

El archivo IMDB Dataset SPANISH.csv contiene 50,000 reseñas, una columna de texto en español (review_es) y etiquetas de sentimiento. Se utilizó exclusivamente review_es; las etiquetas no se usaron para entrenar ni asignar tópicos.

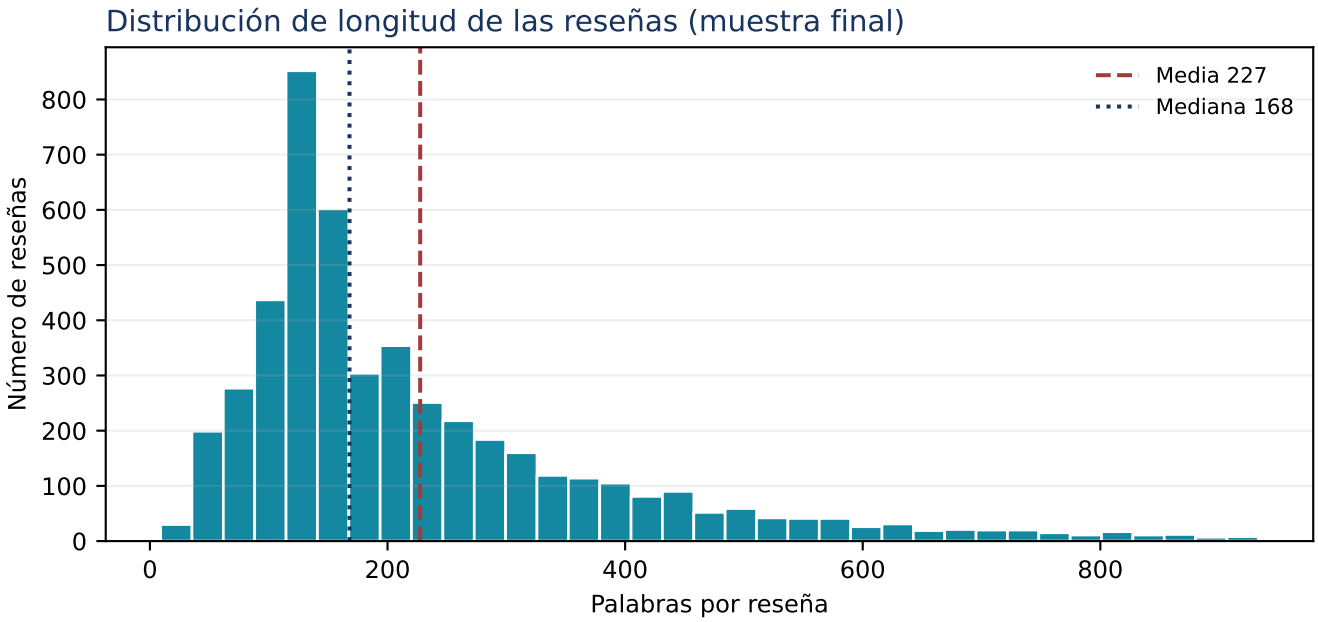
Tras limpiar etiquetas
 y espacios, se conservaron textos de al menos cinco palabras y se quitaron duplicados exactos. El corpus completo aporta 49,599 reseñas únicas. Se tomó una muestra reproducible de 5,000 (semilla 42).

La inspección de la muestra identificó 170 textos en inglés dentro de review_es; se excluyeron con una regla léxica conservadora basada en palabras funcionales. El análisis final usa 4,830 reseñas. Es una depuración práctica, no un clasificador lingüístico especializado.

Criterio y estadísticas de segmentación

Unidad de análisis: una reseña completa equivale a un documento. En la muestra final, la longitud media es 227.5 palabras; la mediana, 168; el mínimo, 9; el máximo, 933; y el percentil 95, 572.

La longitud tiene una cola larga: algunas reseñas son mucho mayores que la mediana. Se dividieron reseñas extensas en fragmentos para respetar el límite de tokens del modelo; luego se promediaron sus embeddings para conservar un vector por reseña.



2. Metodología y comparación

Parámetros que determinan las dos soluciones evaluadas.

Representación y parámetros comunes

Se empleó hiiamsid/sentence_similarity_spanish_es, un modelo de embeddings orientado a similitud semántica en español. Admite hasta 512 tokens por entrada; las reseñas largas se fragmentaron y sus vectores se promediaron.

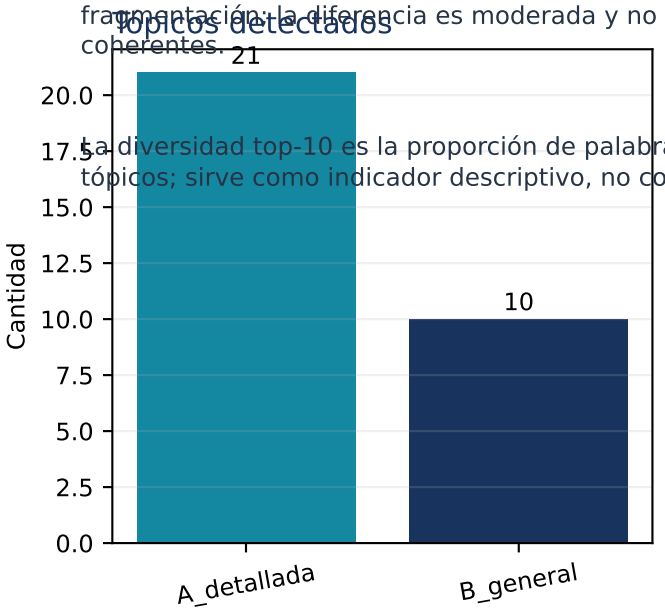
CountVectorizer usa stopwords en español y n-gramas. UMAP reduce los vectores a 5 dimensiones, con distancia coseno, n_neighbors=15 y random_state=42. HDBSCAN usa selección EOM y min_samples=5 para permitir más grupos sin elevar tanto la proporción de ruido.

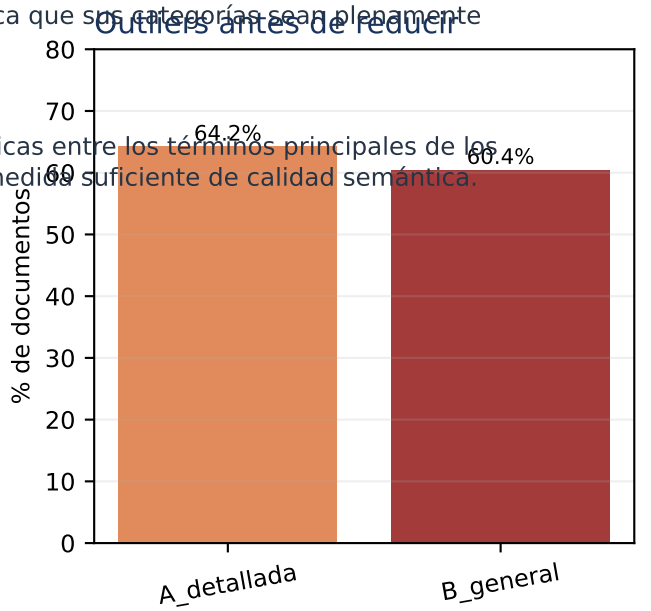
La configuración B_general fija nr_topics=20 como máximo, no como cantidad obligatoria. En esta corrida detectó 10 tópicos; por eso BERTopic no los redujo a 20.

Configuración	min_cluster_size	N-gramas	Tópicos	Outliers iniciales	Diversidad top-10
A_detallada	30	unigramas (1,1)	21	64.20%	0.5143
B_general	60	unigramas + bigramas (1,2)	10	60.43%	0.4300

Lectura de la comparación

A_detallada produjo más tópicos y mayor diversidad léxica, pero también más outliers. B_general formó menos grupos y dejó una proporción de outliers algo menor. Se eligió B_general por su menor fragmentación; la diferencia es moderada y no implica que sus categorías sean plenamente coherentes.





La diversidad top-10 es la proporción de palabras únicas entre los términos principales de los tópicos; sirve como indicador descriptivo, no como medida suficiente de calidad semántica.

3. Tabla de tópicos

Configuración B_general después de tratar los outliers. Los nombres son interpretativos.

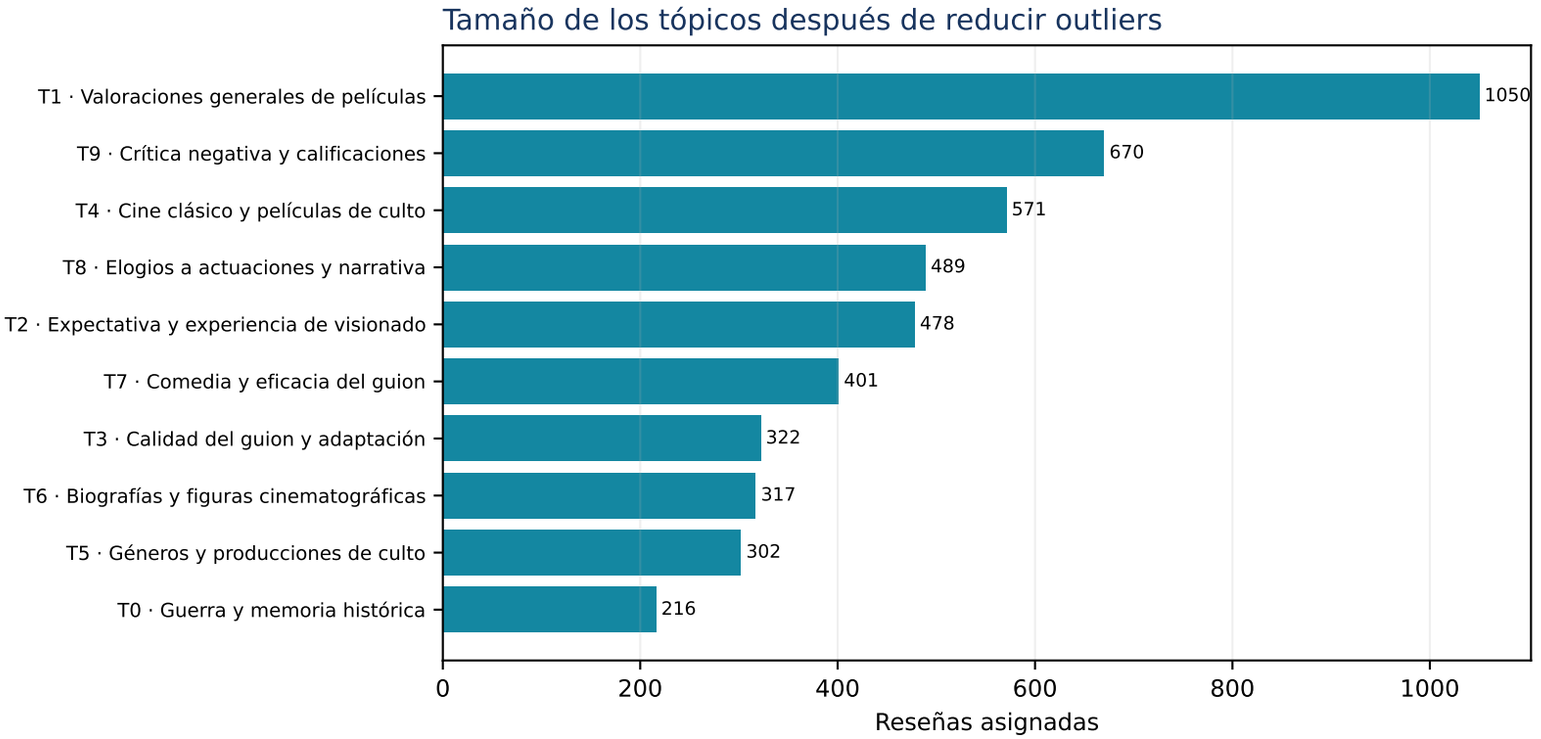
Tópico	Nombre interpretativo	Reseñas asignadas	Términos principales (normalizados)
-1	Reseñas atípicas sin asignación	14	leland, beb, baile, rastreadores, rastreadores journeymer
0	Guerra y memoria histórica	216	película, guerra, más, está, historia
1	Valoraciones generales de películas	1,050	película, más, está, películas, qué
2	Expectativa y experiencia de visionado	478	película, más, historia, está, personajes
3	Calidad del guion y adaptación	322	película, más, películas, realmente, está
4	Cine clásico y películas de culto	571	película, está, más, historia, también
5	Géneros y producciones de culto	302	más, película, está, mejor, años
6	Biografías y figuras cinematográficas	317	película, más, historia, está, también
7	Comedia y eficacia del guion	401	película, más, está, espectculo, realmente
8	Elogios a actuaciones y narrativa	489	película, más, historia, películas, realmente
9	Crítica negativa y calificaciones	670	película, más, películas, he, realmente

Nota de lectura

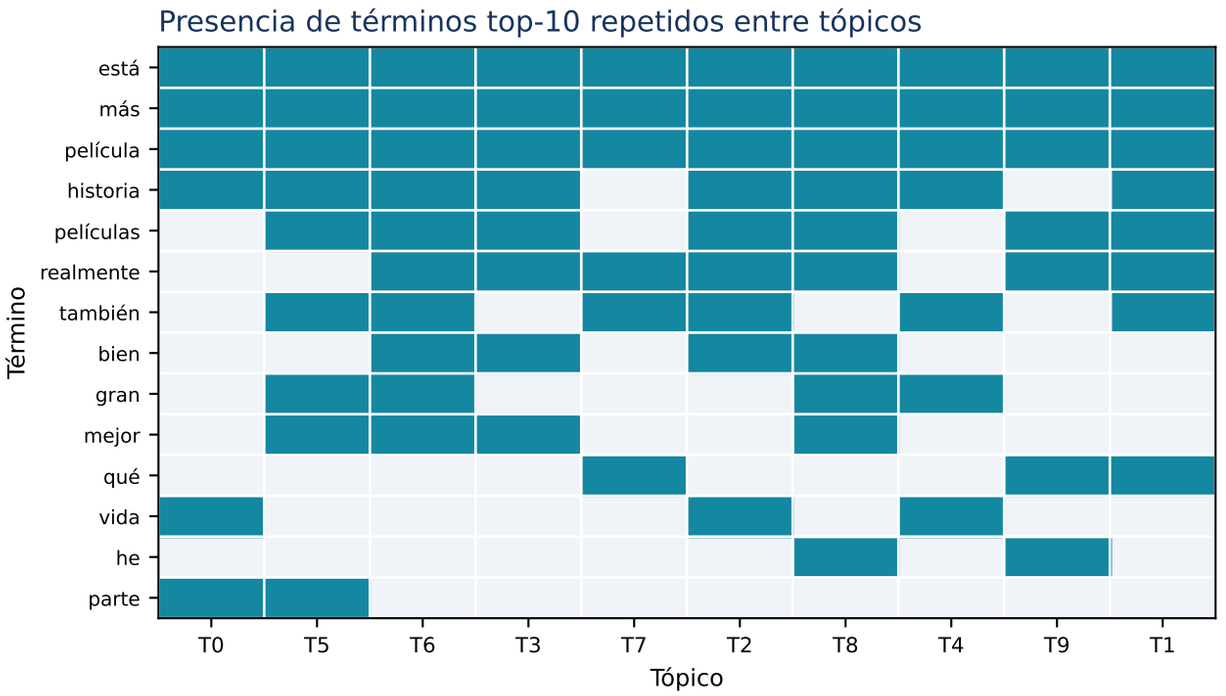
Los términos proceden de la representación c-TF-IDF/MMR. En la salida automática, algunos caracteres acentuados se perdieron; en esta tabla se normalizaron formas evidentes (por ejemplo, “pelcula” a “película”). Los nombres se apoyan además en las reseñas representativas y no deben tomarse como etiquetas validadas.

4. Visualizaciones e interpretación

Gráficas calculadas directamente a partir de las salidas de BERTopic.



Interpretación: los tamaños son desiguales; el tópico 1 es el mayor (1,050 reseñas) y concentra cerca del 22% de las asignadas. No hay un reparto uniforme.



Interpretación: varios términos generales se repiten en distintos tópicos. Esto, junto con ejemplos heterogéneos, sugiere separación temática limitada; los grupos son útiles como exploración, no como clasificación definitiva.

5. Ejemplos representativos (tópicos 0–4)

Dos fragmentos breves por tópico, seleccionados por cercanía al centro del grupo.

Tópico 0 · Guerra y memoria histórica

“La excelencia parece venir rara en Hollwood hoy. Muchos consideran que solo dos de los…”

“He leído tanto el libro como vio la película hoy. La historia es tan poderosa…”

Tópico 1 · Valoraciones generales de películas

“Aquí hay otra película que debe cargarse en un satélite, disparado al espacio y señaló…”

“Corrí a través de esto hace varios años, mientras que el canal navegaba un domingo…”

Tópico 2 · Expectativa y experiencia de visionado

“Las previsualizaciones especiales de Sneak son siempre un buen momento. No importa qué película esté…”

“La única razón por la que sabía de la medianoche, el vaquero era porque estaba…”

Tópico 3 · Calidad del guion y adaptación

“La culpa y la redención son dos de las emociones básicas y los elementos de…”

“Esta película realmente es una bolsa mixta. Por un lado, la historia y el concepto…”

Tópico 4 · Cine clásico y películas de culto

“DVD se ha convertido en el equivalente del antiguo circuito de Doble Bill de la…”

“Algunos podrían recordar si habían visto la película Juno una escena donde Ellen Page tiene…”

6. Ejemplos representativos (tópicos 5–9)

Dos fragmentos breves por tópico, seleccionados por cercanía al centro del grupo.

Tópico 5 · Géneros y producciones de culto

> “¡¡Sí!! Finalmente lo lograron a la perfección. Qué gran idea, una refrescante epopeya de explotación…”

> “Pronto, los estadounidenses se enjugarían sobre una inglaterra oscurecida y dañada, preparándose para invadir Europa,…”

Tópico 6 · Biografías y figuras cinematográficas

> “"La notoria página Bettie" (2005) dirigida por: Mary Harron protagonizada por: Gretchen Mol, Chris Bauer,…”

> “Para mí, personalmente, esta película baja en mis cuatro primeros de todo el tiempo. Sin…”

Tópico 7 · Comedia y eficacia del guion

> “El guión (David H. Steinberg) parecía inicialmente teniendo algunos puntos inteligentes reales que podrían haber…”

> “Crear una comedia es como caminar una cuerda bastante fina. O bien funciona, o no…”

Tópico 8 · Elogios a actuaciones y narrativa

> “Tengo muchas ganas de ver esta película desde que primero atrapé el trailer, y me…”

> “Recuerdo haber capturado esta película en una proyección de C4 hace un año y me…”

Tópico 9 · Crítica negativa y calificaciones

> “Vi la calificación de 7.5 IMDB en esta película y sobre la base de eso…”

> “Veo películas para ganarse la vida, escogiendo cuáles son lo suficientemente buenos para distribuir”

Discusión

Tienen mayor sentido temático los grupos relacionados con guerra e historia, comedia, críticas desfavorables y valoraciones positivas de actuaciones. Otros son amplios o mezclan géneros y argumentos; por ejemplo, los tópicos de valoraciones generales, producciones de culto y figuras cinematográficas no muestran fronteras claras en sus ejemplos.

El análisis inicial marcó 60.43% de reseñas como outliers. La reasignación por embeddings con umbral 0.5 redujo esa cifra a 0.29% (14 reseñas). Reasignar una fracción tan grande puede introducir ruido; por ello se conservan ambos porcentajes y la interpretación es cautelosa.

7. Conclusiones y referencias

Síntesis y declaración de uso de IA.

Conclusiones

La muestra española permitió identificar 10 grupos bajo la configuración general. Los tamaños varían y varios tópicos comparten vocabulario general de reseñas; por eso sus nombres resumen los ejemplos, pero no representan categorías limpias.

La configuración detallada separó más tópicos, aunque aumentó la proporción de outliers. La configuración general ofreció una solución más compacta, pero el alto porcentaje inicial de outliers y su posterior reasignación son limitaciones importantes.

El resultado es exploratorio. Para fortalecerlo convendría probar otras muestras o parámetros, verificar manualmente los temas y medir coherencia semántica antes de afirmar que los tópicos son estables.

Bibliografía

Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv:2203.05794. https://arxiv.org/abs/2203.05794

McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. arXiv:1802.03426.

Campello, R. J. G. B., Moulavi, D., & Sander, J. (2013). Density-Based Clustering Based on Hierarchical Density Estimates. PAKDD, 160–172.

Maas, A. L. et al. (2011). Learning Word Vectors for Sentiment Analysis. ACL. La versión en español analizada se recibió como archivo local; su fuente de traducción no está indicada.

Modelo de embeddings: hiiamsid/sentence_similarity_spanish_es, Hugging Face Model Hub. https://huggingface.co/hiiamsid/sentence_similarity_spanish_es

Declaración de uso de IA

Se utilizaron herramientas de IA como apoyo para depurar el código, organizar el análisis y redactar este informe. La autora debe revisar los nombres e interpretaciones de los tópicos y asumir la responsabilidad de las conclusiones.

Enlace al código: [agregar enlace aquí]